Relazione sul Model Context Protocol (MCP)

Cos'è il Model Context Protocol (MCP)

Il **Model Context Protocol (MCP)** rappresenta un paradigma innovativo di comunicazione tra modelli linguistici di grandi dimensioni (**LLM**) e strumenti esterni. MCP fornisce un livello di astrazione che consente di fornire al modello contesto operativo e accesso a strumenti specializzati senza la necessità di implementare manualmente codice di integrazione per ciascun servizio. In questo modo, lo sviluppo di applicazioni basate su LLM risulta notevolmente semplificato e più modulare.

Il problema affrontato da MCP

Lo sviluppo di sistemi intelligenti che utilizzano LLM in ambienti reali spesso richiede l'accesso a servizi esterni complessi, come ad esempio API pubbliche o private. Consideriamo, ad esempio, un'applicazione in cui l'utente desidera porre domande al LLM sui propri dati GitHub: una richiesta come "Quali pull request aperte ho in tutti i miei repository?" implica una conoscenza approfondita dell'API di GitHub e la capacità di effettuare chiamate contestuali.

Senza MCP, il team di sviluppo dovrebbe:

- Definire e implementare manualmente ogni singolo strumento (tool) corrispondente alle funzionalità di GitHub.
- Gestire la comunicazione tra il modello e il servizio esterno.
- Scrivere e mantenere un considerevole volume di codice di integrazione.
- Garantire aggiornamenti costanti in caso di modifiche alle API esterne.

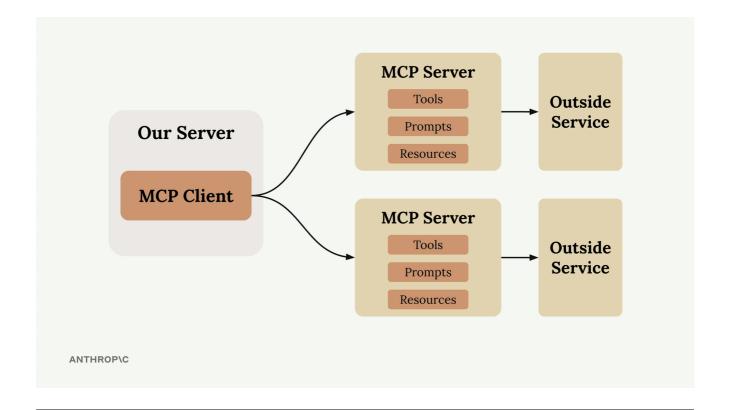
Questo approccio è **oneroso, complesso e difficile da scalare**, soprattutto quando si vogliono supportare numerosi servizi e strumenti.

MCP affronta questo problema in modo strutturato, consentendo di **delegare l'implementazione**, **l'esecuzione e la manutenzione degli strumenti** a server specializzati (MCP Server), riducendo drasticamente la complessità sul lato applicativo (client).

Struttura e funzionamento del Model Context Protocol

MCP si basa su due componenti principali:

- **MCP Client**: È l'interfaccia principale tra il tuo server e uno o più MCP Server. Si occupa di inviare richieste, ricevere risposte e gestire il protocollo di comunicazione.
- MCP Server: È un'interfaccia specializzata che incapsula l'accesso a un servizio esterno (es. GitHub), esponendo un insieme standardizzato di strumenti e risorse utilizzabili dal LLM.



Un aspetto fondamentale di MCP è la sua **indipendenza dal trasporto** ("transport agnostic"). Il protocollo può essere implementato usando diversi canali di comunicazione, tra cui:

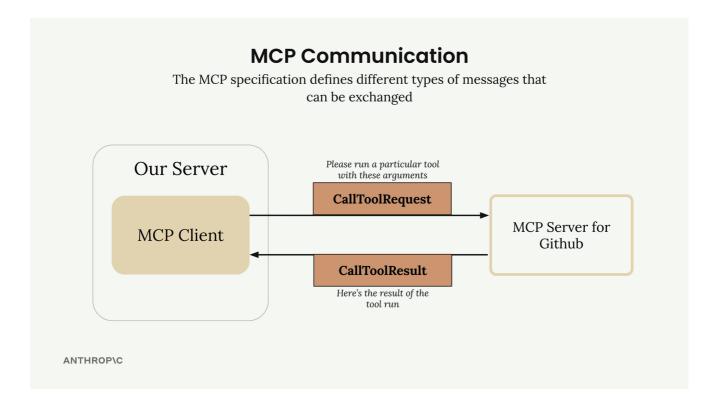
- Input/Output standard (sul medesimo host)
- HTTP
- WebSocket
- Altri protocolli di rete



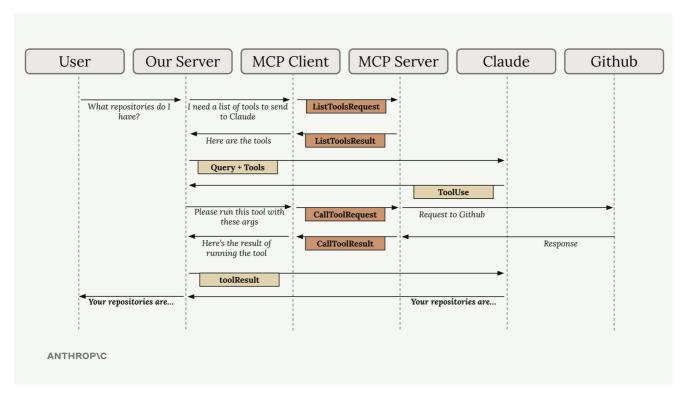
Tipi di messaggi

Il protocollo MCP definisce una serie di messaggi che regolano la comunicazione tra client e server. Tra i più importanti:

- ListToolsRequest / ListToolsResult: Permette al client di ottenere la lista degli strumenti disponibili presso un dato MCP Server.
- CallToolRequest / CallToolResult: Permette di invocare uno specifico strumento ed ottenere il risultato dell'esecuzione.



Flusso operativo completo: dal LLM al servizio esterno



La seguente sequenza descrive il flusso completo di interazione tra utente, applicazione, LLM, MCP e un servizio esterno. Questo schema evidenzia la **modularità** e la **chiarezza delle responsabilità** offerte da MCP:

1. Richiesta dell'utente

L'utente invia una richiesta all'applicazione, ad esempio:

"Quali repository ho su GitHub?"

2. Scoperta degli strumenti

L'applicazione ha bisogno di sapere quali strumenti può mettere a disposizione del LLM per rispondere alla domanda.

3. Interrogazione del client MCP

L'applicazione invia una ListToolsRequest (richiesta per conoscere gli strumenti disponibili) al **client MCP**, il componente che funge da ponte tra l'applicazione e il server MCP.

4. Risposta dal server MCP

Il **server MCP** (servizio specializzato che gestisce l'accesso a uno strumento esterno, come l'API di GitHub) risponde con una ListToolsResult, contenente la lista degli strumenti disponibili (es. get_repos, get_pull_requests, ecc.).

5. Inoltro al LLM

L'applicazione passa al LLM sia la richiesta dell'utente che la lista degli strumenti disponibili.

6. Decisione del LLM

Il LLM analizza la richiesta e decide di utilizzare uno specifico strumento per ottenere le informazioni richieste (ad esempio get_repos).

7. Esecuzione dello strumento

L'applicazione invia una CallToolRequest (richiesta di esecuzione di uno strumento) al client MCP, specificando lo strumento scelto e i parametri necessari.

8. Chiamata al servizio esterno

Il server MCP esegue la chiamata verso il servizio esterno (ad esempio l'API di GitHub) e raccoglie i dati richiesti.

9. Risposta dello strumento

I dati ottenuti vengono restituiti al client MCP tramite un messaggio CallToolResult.

10. Consegna dei dati al LLM

L'applicazione riceve i dati dal client MCP e li invia al LLM.

11. Formulazione della risposta finale

Il LLM elabora una risposta testuale basata sulle informazioni ricevute.

12. Risposta all'utente

Infine, l'applicazione restituisce la risposta generata all'utente.

Conclusione

PROFESSEUR: M.DA ROS

Il **Model Context Protocol** è una risposta efficace e scalabile alla crescente complessità di integrazione tra LLM e servizi esterni. MCP consente infatti di delegare completamente la gestione degli strumenti a server dedicati, rendendo più facile sviluppare applicazioni complesse e riducendo drasticamente l'onere di sviluppo e manutenzione.

La trasparenza del flusso di controllo e la netta separazione delle responsabilità rendono MCP l'architettura adatta per costruire sistemi intelligenti che possono interagire dinamicamente con il mondo esterno.

